

prumo_

a planilha da gratificação da saúde do Recife, lida com aprendizado de máquina

Secretaria de Saúde do Recife (SESAU) · Sistemas de Informação · 2026.2

João Pedro Mamede Dias João Henrique Micucci Matheus Lustosa Rafael Serpa Fernando Fernandez
Gabriel Tenório Cláudio Alves Kerry Muniz Guilherme Cardozo



o caminho de hoje

as cinco etapas da avaliação, cada uma com os números da planilha

01 o problema ENTENDIMENTO DO PROBLEMA	02 o dataset DETALHAMENTO DO DATASET	03 a exploração (eda) ANÁLISE EXPLORATÓRIA (EDA)	04 o tratamento TRATAMENTO E PRÉ- PROCESSAMENTO	05 as features novas FEATURE ENGINEERING
---	---	---	--	--

uma planilha decide a gratificação

cada unidade de saúde ganha nota em quatro indicadores, e o resultado geral é a soma com peso

20% ind1 medicamentos e material	20% ind2 gestão do trabalho	20% ind3 satisfação do usuário	40% ind4 desempenho da unidade
---	--	---	---

resultado geral = $0,2 \times \text{ind1} + 0,2 \times \text{ind2} + 0,2 \times \text{ind3} + 0,4 \times \text{ind4}$

“é tudo manual, via procv e afins”

A SECRETARIA, SOBRE COMO A CONTA É FEITA HOJE

o que o modelo responde

objetivo: descobrir quais indicadores mais pesam para uma unidade ficar abaixo de 90%, e quais unidades se parecem

01

CLASSIFICAR

a unidade fica abaixo de 90%?

ALVO (TARGET)

abaixo_90

binário: 1 ou 0

02

PREVER O NÚMERO (REGRESSÃO)

que resultado geral esperar?

ALVO (TARGET)

geral

contínuo

03

AGRUPAR

quais unidades se parecem?

ALVO (TARGET)

sem alvo

não supervisionado

para que serve a resposta

quatro usos para a gestão da Secretaria, e um limite que não se negocia

01

priorizar

olhar primeiro para quem
pode ficar abaixo de 90%

02

mostrar o que move

em qual indicador uma
melhora rende mais

03

achar erro na planilha

o que a regra espera contra
o que foi lançado

04

comparar parecidos

cada unidade contra as do
mesmo grupo


nenhum resultado do modelo entra no cálculo da gratificação, e o agrupamento é
de unidades, nunca de pessoas

a planilha real, como chegou

enviada pela Secretaria com autorização e sem nenhum dado de pessoa: uma linha por unidade de saúde, mais as dos distritos

244

linhas na planilha



260 colunas cada

196

unidades de saúde



saem 48 linhas de distrito (DS), avaliadas de outro jeito

190

unidades modeladas



saem 6 que não seguem os pesos da portaria

ARQUIVO

ml/data/base nova completa.csv

CODIFICAÇÃO

cp1252

AUTORIZAÇÃO



da Secretaria, registrada na ADR-044

DADO DE PESSOA

nenhum: sem nome, CPF ou matrícula

260 colunas, sete papéis

o começo do nome diz o que a coluna guarda; os números chegam como texto, com % e vírgula





a tabela que o modelo lê

as notas dos quatro indicadores, três categóricas e dois alvos tirados do resultado geral

tipo	CATEGÓRICA NOMINAL 17 tipos de unidade
familia	CATEGÓRICA NOMINAL CAPS, CECO, MAC, UBT, UCIS, USF
distrito	CATEGÓRICA NOMINAL de I a VIII
ind1 a ind4	NUMÉRICA CONTÍNUA a nota de cada indicador
geral	NUMÉRICA CONTÍNUA alvo da regressão
abaixo_90	BINÁRIA alvo da classificação


DISTRIBUIÇÃO DAS CLASSES



quase equilibradas: mesmo assim, separação estratificada e F1

as notas andam em degraus


cada indicador vira nota por faixa, então poucos valores se repetem muito nas 196 unidades




o tipo separa, o distrito não

resultado geral por família de unidade e por distrito sanitário, com a linha dos 90%

POR FAMÍLIA DE UNIDADE



POR DISTRITO SANITÁRIO



o ind3 anda junto com o resultado

correlação entre as notas nas 196 unidades, e as colunas cruas mais ligadas ao resultado geral

ENTRE AS NOTAS

	ind1	ind2	ind3	ind4	geral
ind1	1,00	0,07	0,19	0,16	0,36
ind2	0,07	1,00	0,11	-0,04	0,16
ind3	0,19	0,11	1,00	0,36	0,79
ind4	0,16	-0,04	0,36	1,00	0,36
geral	0,36	0,16	0,79	0,36	1,00

COLUNAS CRUAS MAIS LIGADAS AO RESULTADO • DE -1 A 1



nada falta, e o outlier não é erro


zero ausentes nas 63.440 células; o IQR marca como outlier os tipos que pontuam diferente

MAPA DE AUSENTES



260 colunas × 244 linhas = 63.440

FORA DO IQR, POR NOTA



no resultado geral, 18 são MAC

o que o olho não pega

problemas da planilha que a conversão precisou resolver antes de qualquer conta

201

colunas lidas como texto: número com % e vírgula

49

colunas que misturam 0,8 e 80%

4

metas escritas de dois jeitos, como 20 e 2000%

114

células com vírgula de milhar, em 24 linhas de distrito

96


colunas que não variam entre as unidades

4

colunas de pontos com nome repetido; o ind4 só vem assim, vezes 0,4

seis linhas não fecham a conta

cada ponto é uma unidade: o resultado que os pesos da portaria dão, contra o que a planilha lançou



UNIDADE	ESPERADO	LANÇADO
SAE · I	1,388	0,816
SAE · III	1,373	1,905
SAE · IV	1,329	1,879
NDI · III	1,182	1,792
NDI · VI	1,193	1,799
NDI · IV	1,136	1,765

o que a exploração ensinou

seis achados e o que cada um mudou depois

01

o tipo explica o resultado; o distrito, quase nada

→ tipo vira código e nível

02

o ind3 é a nota mais ligada ao resultado

→ as features novas partem dele

03

as notas andam em degraus

→ o IQR exagera; os outliers ficam

04

nada ausente, mas quase tudo chega como texto

→ converter antes de tudo

05

seis linhas não seguem a conta

→ saem da modelagem

06

classes quase equilibradas

→ estratificar e medir com F1

cada problema, uma decisão


o que a planilha recebeu antes de qualquer modelo, e por quê

PROBLEMA	DECISÃO	POR QUÊ
número guardado como texto	converter, tirando % e vírgula	258 colunas viram número
valores ausentes	nada a preencher; mediana do tipo como rede	0 antes, 0 depois
linhas duplicadas	procurar e remover	nenhuma: uma linha por unidade
ind4 vezes o peso	dividir por 0,4	volta a ser nota
outliers do IQR	manter	tipos reais; árvore não se incomoda
distrito e fora da regra	remover 48 + 6	outra avaliação; conta que não fecha

categoria vira número sem inventar ordem

one-hot onde não há ordem, código onde a árvore dá conta, número onde a ordem é real





família e distrito one-hot	6 + 8 colunas de 0 e 1: o distrito I não é menor que o II
tipo de unidade label encoding	17 valores numa coluna; árvore não lê código como distância
nível do tipo ordinal	USF 1 a 8 e MAC 1 a 4 têm ordem real
padronização	StandardScaler só no K-Means, que mede distância



190 linhas × 28 colunas no fim

seis features novas

todas partem das notas mais ligadas ao resultado, e nenhuma usa o resultado geral: o alvo não vaza

FEATURE	COMO	POR QUÊ	DISTRIBUIÇÃO	ASSIMETRIA
taxa_ind1	atendidos ÷ avaliados	a versão contínua do ind1, que anda em degrau		0,11
ind3_x_ind4	ind3 × ind4	quem vai bem nas duas notas mais fortes		2,69
ind3_abaixo_meta	1 se ind3 < 1	o que derruba MAC 3 e 4		4,96
indicadores_na_meta	quantas notas ≥ 1	quantos indicadores batem 100%		-2,18
desvio_indicadores	desvio das 4 notas	quão desigual a unidade é		1,81
media_blocos_ind4	média de 8 blocos	a variação que a nota do ind4 esconde		-0,30

o que as features novas acrescentam

correlação de cada coluna com o resultado geral e com a classe abaixo de 90%, com as notas de origem ao lado

	COM O RESULTADO GERAL	COM ABAIXO DE 90%
ind3_x_ind4 NOVA	0,93	-0,34
ind3	0,91	-0,31
desvio_indicadores NOVA	0,82	-0,17
ind4	0,49	-0,23
indicadores_na_meta NOVA	0,41	-0,21
ind3_abaixo_meta NOVA	-0,37	0,21
ind1	0,37	-0,70
taxa_ind1 NOVA	0,33	-0,63
ind2	0,27	-0,17
media_blocos_ind4 NOVA	0,11	-0,26

REDUNDÂNCIA

desvio_indicadores · ind3	0,97
ind3_x_ind4 · ind3	0,96
taxa_ind1 · ind1	0,84

para árvore não atrapalha; num modelo linear, ficaria uma só

TESTADAS E DESCARTADAS

log do ind4
a assimetria quase não muda: 1,96 para 1,89

subindicador 2.3
o ind2 é função direta dele

porte da unidade
correlação de -0,001 com o resultado

o que levar daqui

01

a planilha se contradiz

seis linhas não fecham a conta da portaria

02

o modelo vai aprender a regra

o resultado é soma das notas: métrica alta não é mérito

03

ind3 e ind1 movem tudo

um puxa o resultado, o outro decide quem fica abaixo

próximo: XGBoost, LightGBM, CatBoost e stacking para classificar, XGBoost para a regressão e K-Means para agrupar · entrega final 18/11/2026

documento das etapas 1 e 2 [ml/documento-problema-e-dados.md](#) · cadernos das etapas 2 a 5 [ml/notebooks](#), 01 e 02

projeto6-si.vercel.app/ml **perguntas?**