

# prumo\_

a planilha da gratificação da saúde do  
Recife, lida com aprendizado de máquina

Secretaria de Saúde do Recife (SESAU) · Sistemas de Informação · 2026.2

João Pedro Mamede Dias   João Henrique Micucci   Matheus Lustosa   Rafael Serpa   Fernando Fernandez  
Gabriel Tenório   Cláudio Alves   Kerry Muniz   Guilherme Cardozo



C E S A R



# o caminho de hoje

as cinco etapas da avaliação, cada uma com os números da planilha

|                                                               |                                                             |                                                                             |                                                                        |                                                                  |
|---------------------------------------------------------------|-------------------------------------------------------------|-----------------------------------------------------------------------------|------------------------------------------------------------------------|------------------------------------------------------------------|
| <b>01</b><br><b>o problema</b><br>ENTENDIMENTO DO<br>PROBLEMA | <b>02</b><br><b>o dataset</b><br>DETALHAMENTO DO<br>DATASET | <b>03</b><br><b>a exploração<br/>(eda)</b><br>ANÁLISE EXPLORATÓRIA<br>(EDA) | <b>04</b><br><b>o tratamento</b><br>TRATAMENTO E PRÉ-<br>PROCESSAMENTO | <b>05</b><br><b>as features<br/>novas</b><br>FEATURE ENGINEERING |
|---------------------------------------------------------------|-------------------------------------------------------------|-----------------------------------------------------------------------------|------------------------------------------------------------------------|------------------------------------------------------------------|

# uma planilha decide a gratificação

cada unidade de saúde ganha nota em quatro indicadores, e o resultado geral é a soma com peso

|                                               |                                          |                                             |                                             |
|-----------------------------------------------|------------------------------------------|---------------------------------------------|---------------------------------------------|
| <b>20%</b><br>ind1<br>medicamentos e material | <b>20%</b><br>ind2<br>gestão do trabalho | <b>20%</b><br>ind3<br>satisfação do usuário | <b>40%</b><br>ind4<br>desempenho da unidade |
|-----------------------------------------------|------------------------------------------|---------------------------------------------|---------------------------------------------|

resultado geral =  $0,2 \times \text{ind1} + 0,2 \times \text{ind2} + 0,2 \times \text{ind3} + 0,4 \times \text{ind4}$

“é tudo manual, via procv e afins”

A SECRETARIA, SOBRE COMO A CONTA É FEITA HOJE

# o que o modelo responde

objetivo: descobrir o que separa as unidades que ficam abaixo de 90%, e quais unidades se parecem

01

CLASSIFICAR

a unidade fica abaixo de 90%?

ALVO (TARGET)

abaixo\_90

binário: 1 ou 0

02

PREVER O NÚMERO (REGRESSÃO)

que resultado geral esperar?

ALVO (TARGET)

geral

contínuo

03

AGRUPAR

quais unidades se parecem?

ALVO (TARGET)

sem alvo

não supervisionado

# para que serve a resposta

quatro usos para a gestão da Secretaria, e um limite que não se negocia

01

## priorizar

ver primeiro quem fica  
abaixo de 90%, e por quê

02

## mostrar o que separa

em que indicadores as  
unidades se diferenciam

03

## achar conta que não fecha

o que a regra espera contra  
o que foi lançado

04

## comparar parecidos

cada unidade contra as do  
mesmo grupo


nenhum resultado do modelo entra no cálculo da gratificação, e o agrupamento é  
de unidades, nunca de pessoas

# a planilha real, como chegou

enviada pela Secretaria com autorização e sem nenhum dado de pessoa: uma linha por unidade de saúde, mais as dos distritos

244


linhas na planilha



260 colunas cada

196

unidades de saúde



saem 48 linhas de distrito (DS), 6 por distrito

190

unidades modeladas



saem as 6 NDI e SAE, que seguem outra conta

ARQUIVO

ml/data/base nova completa.csv

CODIFICAÇÃO

cp1252

PERÍODO

um retrato só, sem coluna de data

AUTORIZAÇÃO


da Secretaria, registrada na ADR-044

DADO DE PESSOA

nenhum: sem nome, CPF ou matrícula

# 260 colunas, sete papéis

o começo do nome diz o que a coluna guarda;  
os números chegam como texto, com % e vírgula





# a tabela que o modelo lê

as notas dos quatro indicadores, três categóricas e dois alvos tirados do resultado geral

|             |                                                    |
|-------------|----------------------------------------------------|
| tipo        | CATEGÓRICA NOMINAL 17 tipos nas 190 unidades       |
| familia     | CATEGÓRICA NOMINAL CAPS, CECO, MAC, UBT, UCIS, USF |
| distrito    | CATEGÓRICA NOMINAL de I a VIII                     |
| ind1 e ind2 | NUMÉRICA DISCRETA nota por faixa                   |
| ind3 e ind4 | NUMÉRICA nota do indicador                         |
| geral       | NUMÉRICA CONTÍNUA alvo da regressão                |
| abaixo_90   | BINÁRIA alvo da classificação                      |


## CLASSES NAS 190 MODELADAS



quase equilibradas: mesmo assim, separação estratificada e F1

# as notas andam em degraus


cada indicador vira nota por faixa, então poucos valores se repetem muito nas 196 unidades




# o tipo separa, o distrito não

resultado geral por família de unidade e  
por distrito sanitário, com a linha dos 90%

POR FAMÍLIA DE UNIDADE



POR DISTRITO SANITÁRIO



\* só as 6 linhas que seguem outra conta, slide 14

# o ind3 anda junto com o resultado

correlação entre as notas nas 196 unidades, e as colunas cruas mais ligadas ao resultado geral

ENTRE AS NOTAS, NAS 196

|       | ind1 | ind2  | ind3 | ind4  | geral |
|-------|------|-------|------|-------|-------|
| ind1  | 1,00 | 0,06  | 0,19 | 0,16  | 0,36  |
| ind2  | 0,06 | 1,00  | 0,11 | -0,04 | 0,16  |
| ind3  | 0,19 | 0,11  | 1,00 | 0,36  | 0,79  |
| ind4  | 0,16 | -0,04 | 0,36 | 1,00  | 0,36  |
| geral | 0,36 | 0,16  | 0,79 | 0,36  | 1,00  |


COLUNAS CRUAS MAIS LIGADAS AO RESULTADO · DE -1 A 1

|                |  | nas 196 | sem as seis |
|----------------|--|---------|-------------|
| pontos do ind3 |  | 0,92    | 0,91        |
| nota do ind3   |  | 0,79    | 0,91        |
| bloco 4.IX     |  | -0,76   | constante   |
| nota do ind5   |  | 0,66    | -0,02       |
| nota 4.IX.3.I  |  | -0,66   | constante   |
| bloco 4.IV     |  | -0,57   | -0,10       |
| nota 4.IV.1    |  | -0,50   | -0,14       |
| bloco 4.II     |  | 0,49    | 0,07        |

# nada falta, e quase todo outlier é tipo


0% de ausentes nas 63.440 células; o IQR  
marca sobretudo os tipos que pontuam diferente

MAPA DE AUSENTES



260 colunas × 244 linhas = 63.440  
0% em cada uma das 260 colunas

FORA DO IQR, POR NOTA



no resultado geral: 18 MAC, 6 NDI e SAE, 5 outras

# o que o olho não pega

problemas da planilha que a conversão  
precisou resolver antes de qualquer conta

**199**

colunas de número guardadas como texto,  
com % e vírgula

**49**

com % em umas linhas e não em outras;  
só 6 dentro das unidades

**4**

delas são metas escritas de dois  
jeitos, como 20 e 2000%

**114**

células com vírgula de milhar, em 24  
linhas de distrito

**96**


colunas que não variam entre as  
unidades

**4**

colunas de pontos no fim, nota vezes  
peso; 3 repetem o nome da nota

# seis linhas seguem outra conta

cada ponto é uma unidade: o resultado que os pesos da portaria dão, contra o que a planilha lançou



| UNIDADE     | ESPERADO | LANÇADO | IND3 NOS PONTOS |
|-------------|----------|---------|-----------------|
| ● SAE · I   | 1,388    | 0,816   | 20%             |
| ● SAE · III | 1,373    | 1,905   | 80%             |
| ● SAE · IV  | 1,329    | 1,879   | 80%             |
| ● NDI · III | 1,182    | 1,792   | 80%             |
| ● NDI · VI  | 1,193    | 1,799   | 80%             |
| ● NDI · IV  | 1,136    | 1,765   | 80%             |

nas seis: soma dos pontos ÷ 1,7 = lançado

# o que a exploração ensinou

seis achados e o que cada um mudou depois

01

o tipo explica o resultado; o distrito, quase nada

→ tipo vira código e nível

02

o ind3 é a nota mais ligada ao resultado

→ as features partem dele

03

as notas andam em degraus

→ o IQR exagera; tipo real fica

04

nada ausente, mas quase tudo chega como texto

→ converter antes de tudo

05

NDI e SAE seguem outra conta

→ saem, e viram pergunta à Secretaria

06

classes quase equilibradas

→ estratificar e medir com F1

# cada problema, uma decisão


o que a planilha recebeu antes de qualquer modelo, e por quê

| PROBLEMA                   | DECISÃO                                     | POR QUÊ                        |
|----------------------------|---------------------------------------------|--------------------------------|
| número guardado como texto | converter, tirando % e vírgula              | 258 colunas viram número       |
| valores ausentes           | nada a preencher; mediana do tipo como rede | 0 antes, 0 depois              |
| linhas duplicadas          | procurar e remover                          | nenhuma: uma linha por unidade |
| ind4 vezes o peso          | dividir por 0,4                             | volta a ser nota               |
| outliers do IQR            | manter                                      | tipos e notas reais, não erro  |
| distrito, NDI e SAE        | remover 48 + 6                              | outra avaliação; outra conta   |

# como a categoria vira número

one-hot onde não há ordem, código onde a árvore dá conta, número onde a ordem é real





|                                          |                                                             |
|------------------------------------------|-------------------------------------------------------------|
| família e distrito<br><b>one-hot</b>     | 6 + 8 colunas de 0 e 1: o distrito I não é menor que o II   |
| tipo de unidade<br><b>label encoding</b> | 17 valores numa coluna; árvore não lê código como distância |
| nível do tipo<br><b>ordinal</b>          | USF 1 a 8 e MAC 1 a 4: ordem dentro da família              |
| <b>padronização</b>                      | StandardScaler só no K-Means, que mede distância            |



190 linhas × 28 colunas no fim

# seis features novas

todas partem das notas mais ligadas ao resultado;  
nenhuma usa a coluna do resultado geral

| FEATURE             | COMO                  | POR QUÊ                                       | DISTRIBUIÇÃO                                                                          | ASSIMETRIA |
|---------------------|-----------------------|-----------------------------------------------|---------------------------------------------------------------------------------------|------------|
| taxa_ind1           | atendidos ÷ avaliados | a versão contínua do ind1, que anda em degrau |    | 0,11       |
| ind3_x_ind4         | ind3 × ind4           | quem vai bem nas duas notas mais fortes       |    | 2,69       |
| ind3_abaixo_meta    | 1 se ind3 < 1         | o que derruba MAC 3 e 4                       |    | 4,96       |
| indicadores_na_meta | quantas notas ≥ 1     | quantos indicadores batem 100%                |    | -2,18      |
| desvio_indicadores  | desvio das 4 notas    | quão desigual a unidade é                     |   | 1,81       |
| media_blocos_ind4   | média de 8 blocos     | a variação que a nota do ind4 esconde         |  | -0,30      |

# o que as features novas acrescentam

nas 190 modeladas, a correlação de cada coluna com o resultado geral e com a classe abaixo de 90%

|                          | COM O RESULTADO GERAL                   | COM ABAIXO DE 90%                       |
|--------------------------|-----------------------------------------|-----------------------------------------|
| ind3_x_ind4 NOVA         | <div><div></div><div></div></div> 0,93  | <div><div></div><div></div></div> -0,34 |
| ind3                     | <div><div></div><div></div></div> 0,91  | <div><div></div><div></div></div> -0,31 |
| desvio_indicadores NOVA  | <div><div></div><div></div></div> 0,82  | <div><div></div><div></div></div> -0,17 |
| ind4                     | <div><div></div><div></div></div> 0,49  | <div><div></div><div></div></div> -0,23 |
| indicadores_na_meta NOVA | <div><div></div><div></div></div> 0,41  | <div><div></div><div></div></div> -0,21 |
| ind3_abaixo_meta NOVA    | <div><div></div><div></div></div> -0,37 | <div><div></div><div></div></div> 0,21  |
| ind1                     | <div><div></div><div></div></div> 0,37  | <div><div></div><div></div></div> -0,70 |
| taxa_ind1 NOVA           | <div><div></div><div></div></div> 0,32  | <div><div></div><div></div></div> -0,63 |
| ind2                     | <div><div></div><div></div></div> 0,26  | <div><div></div><div></div></div> -0,18 |
| media_blocos_ind4 NOVA   | <div><div></div><div></div></div> 0,11  | <div><div></div><div></div></div> -0,25 |

## REDUNDÂNCIA

|                                                                      |       |
|----------------------------------------------------------------------|-------|
| ind3 · desvio_indicadores                                            | 0,97  |
| ind3 · ind3_x_ind4                                                   | 0,96  |
| ind3_x_ind4 · desvio_indicadores                                     | 0,95  |
| ind1 · taxa_ind1                                                     | 0,84  |
| ind3_abaixo_meta · indicadores_na_meta                               | -0,80 |
| para prever, a árvore aguenta; para ler a importância, ela se divide |       |

## TESTADAS E DESCARTADAS

- log do ind4  
a assimetria quase não muda: 1,96 para 1,89
- subindicador 2.3  
o ind2 é função direta dele
- porte da unidade  
quase nenhuma relação linear: -0,001

# o que levar daqui

01

**seis linhas seguem outra conta**

todas as NDI e SAE, fora dos pesos da portaria

02

**o modelo vai aprender a regra**

o resultado é soma das notas: métrica alta não é mérito

03

**ind3 e ind1 é que variam**

um explica o resultado, o outro separa quem fica abaixo

próximo: XGBoost, LightGBM, CatBoost e stacking para classificar, XGBoost para a regressão e K-Means para agrupar · entrega final 18/11/2026

documento das etapas 1 e 2 [ml/documento-problema-e-dados.md](#) · cadernos das etapas 2 a 5 [ml/notebooks](#), 01 e 02

[projeto6-si.vercel.app/ml](https://projeto6-si.vercel.app/ml)    **perguntas?**